

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное
учреждение высшего образования
«КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»
Институт информационных технологий и интеллектуальных систем

ОТЧЕТ

**о прохождении производственной (технологической (проектно-
технологической)) практики**

Обучающийся Набиуллин Камиль Маратович _____
(ФИО, группа) (подпись)

Руководитель практики от КФУ:

(ФИО, должность)

Оценка за практику: _____
(подпись руководителя практики)

Дата сдачи отчета: 26.07.2025

Казань – 2025 г.

Содержание

Введение	3
1. Загрузка данных	4
1.1. Описание датасета	4
1.2 Загрузка данных из CSV в DataFrame	5
2. Предобработка и разведочный анализ данных	8
2.1 Предобработка данных	8
2.2 Разведочный анализ данных	9
Заключение	21
Список использованных источников	23

Введение

Производственная практика является одним из компонентов и составной частью учебного процесса студентов бакалавриата. Данный вид практики выполняет функции общепрофессиональной подготовки в части формирования необходимых компетенций и подготовки студентов к будущей профессиональной деятельности.

Дата начала практики: 14.07.2025 г.

Дата окончания практики: 26.07.2025 г.

Место прохождения практики: ООО Аналитика.

Цель прохождения практики: Получение практических навыков в области анализа данных и подготовки для дальнейшей разработки моделей машинного обучения для прогнозирования параметров промышленного процесса.

Для достижения поставленной цели практики были сформулированы следующие задачи:

- 1) Загрузить и изучить набор данных из Kaggle: Industrial Data from the Arc Furnace
- 2) Выполнить предобработку данных: обработать пропуски, выбросы, преобразовать признаки.
- 3) Провести разведочный анализ данных для понимания их структуры и особенностей для дальнейшего отбора признаков, обработки данных и обучения моделей

1. Загрузка данных

1.1. Описание датасета

Набор данных “Industrial Data from the Arc Furnace” [1] доступен на платформе Kaggle и содержит информацию о процессе плавки в дуговой печи.

Этот процесс включает нагрев металлического лома и других материалов с помощью электрической дуги, создаваемой между электродами и шихтой, для достижения высоких температур. Основные этапы включают загрузку шихты (металлический лом, флюсы, ферросплавы), плавление, рафинирование (удаление примесей), корректировку химического состава и выпуск расплавленной стали в ковш.

Данные включают химические измерения, параметры температуры и степени окисления, информацию о добавках и материалах, а также данные о работе трансформатора печи.

Анализ этих параметров позволяет изучить взаимосвязи между условиями плавки и свойствами конечного продукта, что делает набор данных ценным для прогнозирования температуры, степени окисления и химического состава стали.

1.2 Загрузка данных из CSV в DataFrame

Данные были загружены с использованием библиотеки pandas в среде Jupyter Notebook. Для каждого файла был создан отдельный DataFrame.

Для эффективной загрузки и унифицированной обработки данных из набора «Industrial Data from the Arc Furnace» был разработан Python-модуль load_data.py. Модуль предназначен для автоматизированной загрузки всех CSV-файлов из директории data в объекты DataFrame с использованием библиотеки pandas. Он обеспечивает корректное преобразование типов данных, обработку дат и числовых столбцов, а также обработку ошибок, связанных с отсутствием файлов.

Основные особенности модуля:

- Автоматизация загрузки: Все файлы обрабатываются в едином цикле, что упрощает управление набором данных.
- Конфигурация файлов: Для каждого файла определены параметры в словаре file_configs, включая:
 - Список столбцов с датами (parse_dates) для преобразования в формат DateTime с использованием соответствующего формата (date_format).
 - Список числовых столбцов (decimal_columns) для преобразования в тип float, с учетом запятой как десятичного разделителя.
- Гибкость: Модуль легко расширяем для добавления новых файлов или изменения параметров обработки.

Пример конфигурации:

```
'eaf_temp.csv': {  
    'parse_dates': ['DATETIME'],  
    'decimal_columns': ['TEMP', 'VALO2_PPM'],  
    'date_format': '%Y-%m-%d %H:%M:%S'
```

```
}
```

Модуль использует функцию `load_file`, которая принимает имя файла и параметры из конфигурации, загружает CSV-файл с помощью `pd.read_csv`, применяет преобразование типов данных и возвращает `DataFrame`. Основным циклом проходит по списку файлов, создавая словарь `dataframes`, где ключи — имена файлов без расширения, а значения — соответствующие `DataFrame`:

```
def load_file(filename, parse_dates=None, decimal_columns=None,
               date_format=None):
    file_path = '../' + os.path.join(data_dir, filename)
    try:
        df = pd.read_csv(file_path, decimal=',',
                        parse_dates=parse_dates or [], date_format=date_format)

        if decimal_columns:
            for col in decimal_columns:
                if col in df.columns:
                    df[col] = pd.to_numeric(df[col],
                        errors='coerce')

    return df
except FileNotFoundError:
    print(f"Файл {file_path} не найден.")
    return None

for file in files:
    config = file_configs.get(file, {'parse_dates': [],
        'decimal_columns': [], 'date_format': None})
    df = load_file(file, config['parse_dates'],
        config['decimal_columns'], config['date_format'])
    if df is not None:
        df_name = file.split('.')[0]
```

```
dataframes[df_name] = df
```

После загрузки были выполнены следующие шаги предобработки:

- Для eaf_transformer: преобразование столбца DURATION из формата “НН:ММ” в числовой формат в минутах с помощью `pd.to_timedelta`.
- Удаление лишних столбцов, таких как Unnamed: 0 в ferro.

Были обнаружены пропущенные значения, например, 310 пропусков в столбце DATETIME файла ladle_tapping и от 368 до 1292 пропусков в химических измерениях файла eaf_final_chemical_measurements – вызваны отсутствием измерений. Эти пропуски требуют дальнейшей обработки.

2. Предобработка и разведочный анализ данных

2.1 Предобработка данных

Для подготовки данных к анализу были выполнены следующие шаги:

- Обработка пропущенных значений: Пропуски в `ladle_tapping` (310 в `DATETIME`) и `eaf_final_c`(368–1292 в химических измерениях) были отмечены для дальнейшей обработки - удаления строк.
- Обработка выбросов: Аномальные значения в `VALO2_PPM` (0 и 9999 ppm) были исключены или заменены для анализа.
Температуры ниже 1450°C и выше 1800°C были отфильтрованы или ограничены.
- Преобразование данных: Логарифмическое преобразование (`np.log1p`) применено к `VALO2_PPM` для нормализации распределения.
- Объединение данных: Данные из разных файлов (`eaf_temp`, `eaf_final_chemical_measurement`) были объединены по ключам `HEATID` и `DATETIME` для комплексного анализа.
- Значения измерений химических элементов в плавках обычно не превышает одного процента, в следствии чего соответствующие измерения были удалены.

2.2 Разведочный анализ данных

Разведочный анализ данных (EDA) был проведен для понимания структуры данных, выявления распределений и взаимосвязей между переменными. Основное внимание уделялось данным о температуре, степени окисления и химическом составе.

В файле `eaf_temp.csv` содержатся измерения температуры (TEMP) и степени окисления (VALO2_PPM).

Основные статистические характеристики (до обработки):

- TEMP (температура):
- Среднее: 1632.88°C, медиана: 1635°C — температура стабильно в районе 1600–1650°C.
- Минимум: 1115°C, максимум: 1850°C — минимальное значение кажется низким для рабочей печи.
- Стандартное отклонение (27.41°C) небольшое, значит данные стабильны.

VALO2_PPM (степень окисления):

- Среднее: 891.92 ppm, медиана: 797 ppm — средняя степень окисления умеренная.
- Минимум: 0 ppm, максимум: 9999 ppm — нули объясняются описанием датасета (измерение не проводилось), а 9999 — аномалия.
- Стандартное отклонение (1271.28) большое, что указывает на широкий разброс из-за нулей и выбросов.

Для визуализации распределений были построены гистограммы (рис. 1, рис. 2) и боксплоты. Гистограмма для TEMP показала нормальное распределение с небольшими выбросами, в то время как для VALO2_PPM

распределение скошено вправо из-за аномальных значений (0 и 9999 ppm). Боксплот для TEMP (рис. 3) выявил выбросы, включая значения ниже 1500°C и выше 1800°C, которые могут быть связаны с ошибками измерений или начальными стадиями процесса.




Рисунок 1 – Гистограммы распределения температуры и окисления




Рисунок 2 – Гистограммы распределения окисления после исключения выбросов

Распределение сильно скошено вправо, пиковая плотность около 600–1200 ppm, с длинным «хвостом» до ~2000 ppm и единичными точками дальше.




Рисунок 3 – Боксплот по измерениям температуры

Выбросы:

Сверху: значения до ~1820 °С — пики при перегреве.

Снизу: значения ниже 1500 °С (включая один экстремальный выброс ~1100 °С) — ошибки измерения или очень ранние замеры на старте плавки.

Распределение степени окисления на боксплоте (рис. 4) имеет асимметрию вправо.

Возможна нормализация или логарифмическое преобразование признака перед подачей в модель для уменьшения влияния хвост.




Рисунок 4 - Боксплот по измерениям окисления

Графики динамики температуры и окисления для трёх плавов с наибольшим количеством измерений (рис. 5) показал, что резкие скачки температуры часто сопровождаются скачками окисления.

Корреляция Пирсона 0.434 между температурой (TEMP) и окислением (VALO2_PPM_log) (рис. 6) указывает на умеренную положительную линейную связь. Это подтверждает, что повышение температуры в печи, вероятно, усиливает окислительные процессы, что логично для металлургии.

Однако значение менее 0.5 говорит о том, что связь не является доминирующей, и на окисление могут влиять и другие факторы. Для моделирования стоит учитывать возможную мультиколлинеарность, но она не критична на данном уровне.

Динамика температуры и окисления для топ-3 плавов




Рисунок 5 - Графики динамики температуры и окисления




Рисунок 6 - Зависимость окисления от температуры

Гистограмма распределения химических измерений (рис. 7) показала следующее:

- Распределение сильно смещено влево (правостороннее):
- Большинство значений сосредоточено около 0–0.05%, что говорит о низком содержании легирующих примесей в составе.
- Есть длинные хвосты справа:
- У некоторых элементов есть значения $> 0.2\%$, достигающие даже до 0.7% .
- Это могут быть аномалии, ошибки анализа, либо отдельные партии легированных сталей (например, с повышенным содержанием Ni, Mo и пр.).

- VALC, VALMN и VALSI — наиболее выраженные: их распределение шире, и они, вероятно, чаще используются как регулярные легирующие компоненты.
- VALCU, VALCR, VALMO и VALNI — могут быть целевыми для предсказания, особенно если они варьируются от партии к партии.




Рисунок 7 - Гистограмма распределения химических измерений

Таблица корреляций между химическими элементами (рис. 8) говорит о том, что в целом, большинство коэффициентов корреляции невелики, что указывает на относительную независимость большинства элементов в составе.

Наиболее выраженные положительные корреляции: VALC и VALMN: $r = 0.59$

Углерод и марганец влияют на прочность и могут дозироваться совместно - VALCR и VALCU: $r = 0.55$. Возможный признак специальных легированных сталей (например, нержавеющей) - VALMN и VALCR: $r = 0.52$




Рисунок 8 - Таблица корреляций между химическими элементами

Анализ корреляций (рис. 9) между целевыми признаками – температурой, окислением и измерениями химических элементов показал:

Сильные отрицательные корреляции наблюдаются с углеродом и марганцем – VALC – 0.50, VALMN – 0.47. Это означает, что при увеличении содержания углерода, марганца степень окисления уменьшается.

Температура слабо положительно связана с содержанием серы и хрома.

Наблюдаются группы сильно коррелирующих элементов, что важно учитывать при дальнейшем анализе или моделировании




Рисунок 9 - Анализ корреляций (рис. 9) между температурой, окислением и измерениями химических элементов

Корреляции целевых признаков с другими признаками. Выделены следующие ключевые корреляции с температурой (рис. 10): CHARGE_AMOUNT (0.2148) - это общий вес добавок. Корреляция может указывать на то, что больший заряд способствует нагреву, возможно, из-за увеличения массы материала для нагрева.

Слабые корреляции могут быть связаны с нелинейными эффектами.




Рисунок 10 - Корреляции признаков с температурой

Окисление сильно зависит от химического состава (рис. 11) (особенно углерода и марганца) и температуры, что согласуется с металлургическими процессами в электро-дуговой печи.




Рисунок 11 - Корреляции признаков с окислением

Корреляции с химическими элементами (рис. 12)

TAP: Стадия трансформатора из `eaf_transformer` часто коррелирует с элементами (например, 0.163 с VALS, 0.101 с VALMN). Это может отражать влияние электрической мощности на финальные стадии плавки.

Слабые корреляции с параметрами процесса (например, TAP, CHARGE_AMOUNT) указывают на доминирование неучтённых факторов (например, динамики процесса), необходимость новых (преобразованных) признаков или нелинейности зависимостей.




Рисунок 12 - Корреляции с химическими элементами

Заключение

Данная производственная практика была направлена на формирование следующих компетенций:

Шифр компетенции	Расшифровка приобретаемой компетенции
ОПК-4	Способен участвовать в разработке стандартов, норм и правил, а также технической документации, связанной с профессиональной деятельностью
ОПК-5	Способен устанавливать программное и аппаратное обеспечение для информационных и автоматизированных систем
ОПК-6	Способен разрабатывать алгоритмы и программы, пригодные для практического использования, применять основы информатики и программирования к проектированию, конструированию и тестированию программных продуктов
УК-6	Способен управлять своим временем, выстраивать и реализовывать траекторию саморазвития на основе принципов образования в течение всей жизни

В ходе практики были выполнены задачи и получены навыки по предобработке данных, визуализации, проведения исследовательского анализа (EDA), изучению корреляций и работе с промышленными наборами данных.

Все запланированные задачи были выполнены. Проведенный разведочный анализ данных позволил выявить ключевые характеристики набора данных, связанные с процессом плавки в дуговой печи. Корреляционный анализ выявил важные взаимосвязи между химическим составом, температурой и степенью окисления и слабые корреляции с нецелевыми признаками. Хотя были выявлены лишь слабые корреляции, что

может быть связано с нелинейными зависимостями или отсутствием важных переменных.

В дальнейшем стоит попробовать нелинейные модели или доработать признаки для повышения точности с целью работы с моделями машинного обучения.

Список использованных источников

1. Industrial Data from the Arc Furnace // – Kaggle URL: <https://www.kaggle.com/datasets/yuriykatserdata-from-the-arc-furnace/data> (дата обращения: 14.07.2025).
2. EDA // – Yandex URL: https://disk.yandex.ru/d/rDIHlhLJqYlY4g/EDA_P1.ipynb (дата обращения 14.07.25)
- 3 Lesson 2 Correlation analysis // – Kaggle URL: <https://www.kaggle.com/code/emstrakhov/lesson-2-correlation-analysis> (дата обращения 15.07.25)